

**國立臺北科技大學電子工程系 113 年度**

**實務專題成果報告書**

**新世代神經接收器於多通道環境之綜效評析——  
——結合傳統解碼與深度學習架構的全面比較**

專題執行期間：114 年 02 月 17 日起至 114 年 05 月 26 日止

班級：電子三乙

學號：111360201

姓名：盧詠林

指導教授：曾柏軒教授

中 華 民 國 114 年 05 月 26 日

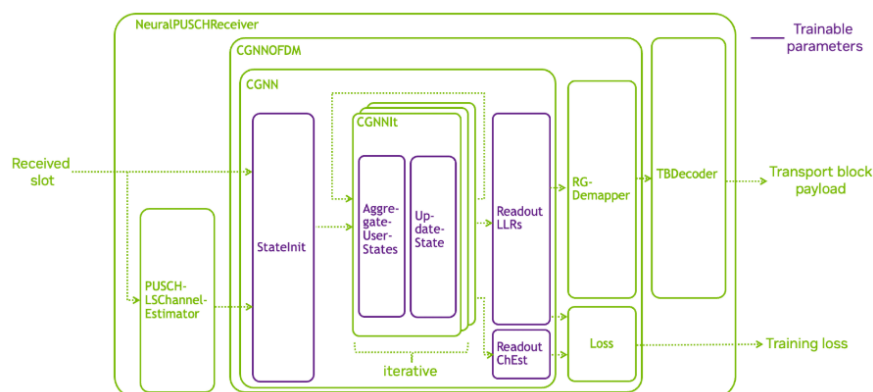
## 摘要

隨著人工智慧技術的快速發展，深度學習已被引入無線通訊領域，以期解決傳統接收器因依賴統計模型與線性解碼（如 LMMSE）而在多徑衰落、建築遮蔽及干擾嚴重的場域中所面臨的高 BLER 與運算複雜度問題。此外，不同錯誤更正碼需求造成的硬體設備頻繁變更，也導致資源浪費。為此，本研究採用 Convolutional & Graph Neural Network（CGNN）架構的神經接收器：利用 CNN 提取時頻二維網格中的局部特徵，並以 GNN 模型化用戶間的干擾關係，通過訊息傳遞迭代消除多用戶信號相互影響。同時，引入 Munich 場景的射線追蹤通道並生成覆蓋地圖，依據 UE 取樣位置為 NRX 微調提供專屬、真實的場域通道資料，期望在實務部署中顯著降低 BLER 並提升系統可靠性與效率。

本研究方法分五階段：首先使用 Munich 場景之三維建築輪廓與地形，並設定 OFDM 編碼與基地台 / UE 天線佈局後，計算水平與垂直偏振路徑增益。接著，將多徑增益依最大值正規化至 0 dB，並加入  $\pm 2$  dB 隨機雜訊模擬 ADC 量化誤差，將複數通道矩陣  $H$ 、延遲、SNR、坐標等封裝為 TFRecord。第四，以 UMi 預訓練權重為初始，凍結前端卷積層，分別在 1 K、100 K 迭代次數下微調後端解碼層。最後，在 2–15 dB SNR 範圍內，以 TBLER 為指標，並與 LMMSE+K-best、PerfCSI+K-best 進行多次獨立對照實驗，驗證場域專屬 NRX 的性能優勢。


## 1 專題簡介：

- 1.1 研究背景：隨著現今人工智能崛起，也造就了人工智能可應用於各個層面。在傳統的通訊系統中，傳統的解碼器隨著雜訊、衰落與干擾嚴重等場域增加，而會使訊號的接收位元錯誤率提升[3]；並且現今高傳輸速率兩低延遲速度的需求下，其解碼的運算複雜度更高[4]；最後，其硬體設備會隨著不同的錯誤更正碼需求而有所改變，也就造成了硬體設備的浪費[6]；因此參考了文獻中的研究主題神經接收器（Neural Receiver）來改善以上問題，而本次研究僅針對場域的部分進行設計以及解析。
- 1.2 研究目的：神經接收器（Neural Receiver）顧名思義就是其接收器的架構為一神經網路架構。而本次的神經接收器架構為 CGNN 架構 (Convolutional & Graph Neural Network)，其 CNN 的作用為在時間-頻率二維網格（如語音梅爾頻譜圖或無線訊號時頻圖）上應用卷積運算，提取局部時頻特徵；而 GNN 為利用圖結構建模用戶間干擾關係，透過訊息傳遞機制迭代消除多用戶訊號間的相互影響[5]。(如圖一)



(圖一)：神經接收器（Neural Receiver）之基礎架構。

並且，為了能應用於各種不同的特定場域，於是我們引進了射線追蹤通道（Ray Tracing Channel）。射線追蹤通道首先需要先引入特地場景(此次專題引入 munich 場景作為使用)，並且設定其傳輸天線與接收天線的數量及位置與通道編碼方式(此專題使用 OFDM)，最後再根據人物位置，生成取樣的覆蓋圖。(如圖二)



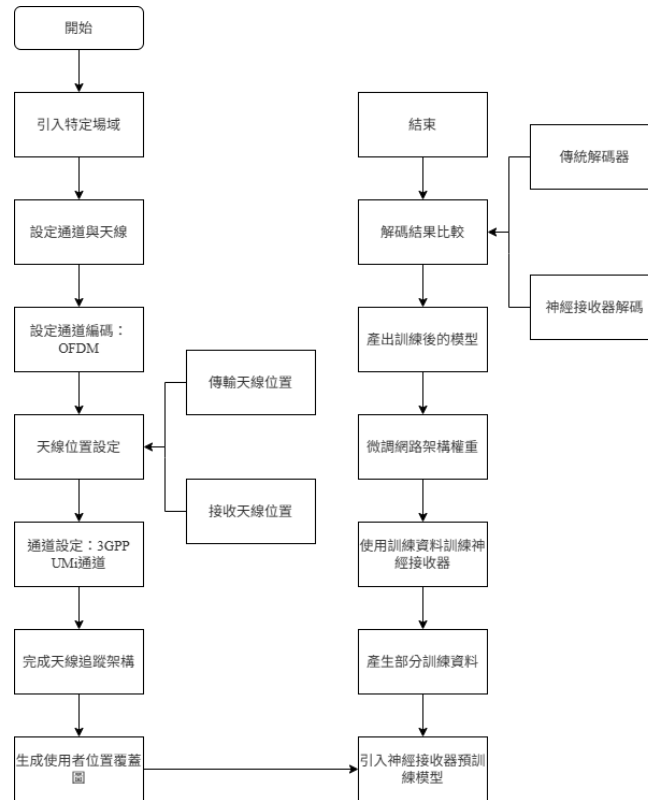
(圖二)：UE 位置取樣所需之覆蓋地圖。

透過此覆蓋圖可以得知在特定區域的信號覆蓋範圍與品質，並且也對於規劃、優化與維護網路至關重要。

- 1.3 研究重要性及貢獻：此重要性主要體現在可以針對特定場域，利用天線追蹤通道的特性，製作出專門針對該場環境優化的神經接收器（Neural Receiver）。透過深度學習模型對該場域的多路徑傳輸、訊號衰退及乾擾等複雜通道效應進行建模與補償，神經接收器能有效提升訊號解碼的準確度與穩定性，顯著改善傳統解碼器在面對動態變化通道時的效能瓶頸。

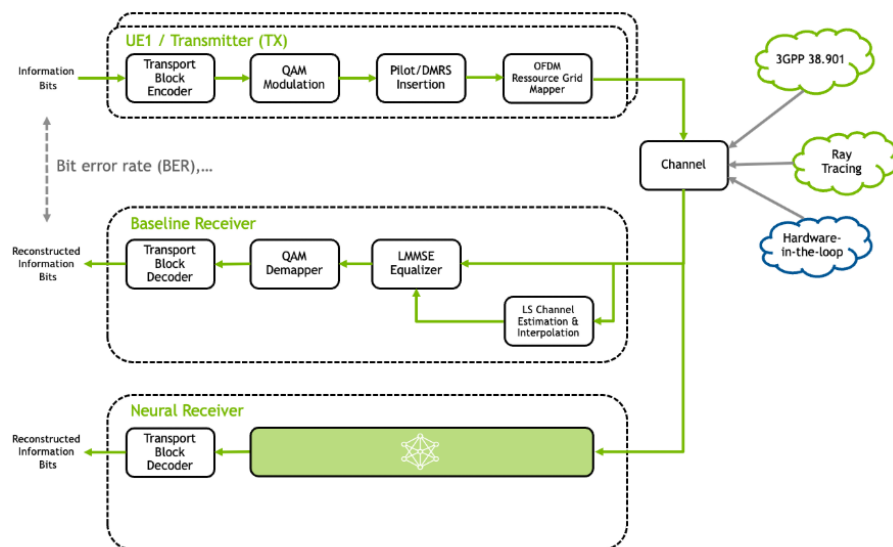
## 2 研究方法：

### 2.1 研究流程圖(如圖三)：




(圖三)：研究詳細流程。

### 2.2 研究方法：首先須先介紹通訊系統的整體架構圖[1] (如圖四)



(圖四)：通訊系統簡易架構流程圖。

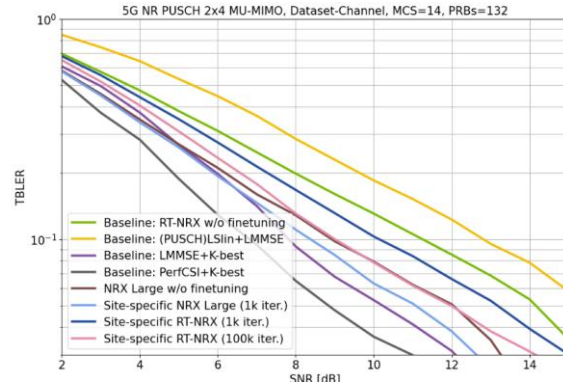
在固定傳輸端架構後，首先定義傳統的接收解碼器 (Baseline Receiver) 使用 perfect CSI、LMMSE 進行通道解碼，再來就是定義神經接收器 (Neural Receiver)，將通道解碼的流程化成一神經網路架構—CGNN。再來引入特定場域 (此處引用 SIONNA 平台所提供之 Munich 場域)，並設定其傳輸與接收天線 (引用 SIONNA 平台所內建之天線)，接著取樣其使用者端之接收位置並產生其覆蓋圖(如圖二)。再來便是產生此特定場域之訓練資料(用於微調權重)，透過上面步驟所產生之覆蓋圖中，隨機取樣 1000 點(注意：此取樣點之通道脈衝響應不可為 0)，產生訓練資料。接著，根據此訓練資料產生其計算資料集；此資料集使用兩種軌跡，一種軌跡為使用者移動速度為 3.5 m/s，另一軌跡為使用者移動速度為 3.0 m/s，最後產生此場域與使用者移動軌跡之整合之覆蓋圖極其資料集。(如圖五)



(圖五)：場域與使用者移動軌跡覆蓋圖。

最後將所得之資料集投入至已有預訓練之神經接收器進行架構，透過

上述的少量資料，來對神經接收器的權重進行微調，最後再與未微調的神經接收器，以及一般通道下的傳統接收器比較其效能。(如圖六)



(圖六)：一般通道及特定場域之不同接收方式的必較。

2.3 研究原因：由於各種不同的解碼方式通常需要對應不同的傳統解碼器硬體設備[7]，這不僅增加了系統設計的複雜度，也導致硬體資源的重複配置與浪費。為了解決這一問題，透過引入神經接收器 (Neural Receiver) 技術，可以大幅提升硬體資源的利用效率。神經接收器具備高度的可調適性與泛化能力，能夠在同一套硬體架構下透過調整神經網路權重來適應不同的解碼任務，避免了傳統方法中為每種解碼方式專門設計硬體的繁瑣與成本負擔。此外，神經接收器能根據不同場域的通道特性自動學習並優化權重參數，使其在多變且複雜的無線環境中仍能保持優異的解碼性能。這種場域專屬的自適應能力不僅擴展了神經接收器的應用範圍，也為未來多樣化的通訊場景提供了更靈活且高效的解決方案。因此，研究並發展神經接收器技術具有重要的實際意義和廣泛的應用前景。

### 3 研究成果：

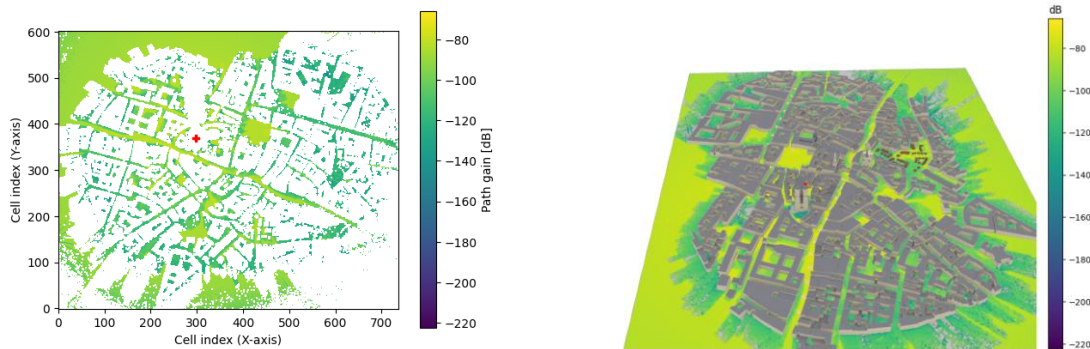
- 3.1 完成工作：著重於天線追蹤通道（Ray Tracing Channel）與神經接收器（Neural Receiver）的架構整合。首先根據文獻[1]所提到之神經網路架構，可於 Sionna 平台之參考範例[7]稍加進行少部分修改可得，而單一的射線追蹤通道亦可從 Sionna 平台參考範例[7]，並修改部分接收器參數可得，而透過上述兩者參考範例，來將通道區塊以及接收器區塊進行整合，以此整合出特定場域的神經接收器。為了比較傳統解碼器與神經接收器的性能，因此再引入傳統的接收解碼器(perfect CSI、LMMSE)，最後分別進行 BLER 的運算，生成出結果圖。至於神經接收器不同迭代次數的部分，有將訓練資料集的訓練次數進行修改，也分別得出不同迭代次數所微調之神經接收器。
- 3.2 解決方案：我們首先以 Sionna 的射線追蹤範例載入場景(.xml)，設定工作頻率與天線陣列，模擬多徑反射與繞射，得到通道響應  $H$  與噪聲後的接收訊號  $y$ 。接著，依據文獻[1]提出的多層全連接網路，建立神經接收器，來計算其各層之間的權重。為了比較性能，我們同時實作 Perfect CSI 與 LMMSE 解碼作為基準，並計算 BLER。模擬在 0–20 dB SNR 範圍內進行，每兩分貝一點；神經接收器則於不同迭代次數訓練後，比較各模型的收斂速度與最終 BLER。最後，以 BLER vs. SNR 曲線直觀呈現神經接收器相對於傳統方法的優勢。



### 3.3 成果展示：

#### 3.3.1 覆蓋地圖 ( Coverage Map ) : 透過 Ray Tracing 功能所得出內建之覆蓋


圖，得出在定位使用者位置時(圖七紅點)，接收者在接收時附近位置的訊號衰減(以 dB 表示)。另一張圖為當使用者有定速(圖八紅點)的軌跡時，其接收訊號的衰減的場景與使用者覆蓋圖。



(圖七)：UE 位置取樣所需之覆蓋地圖。(圖八)：場景與用戶軌跡之覆蓋地圖。

#### 3.3.2 BLER 性能曲線：圖 9 顯示，在 Baseline (3GPP UMi) 場景下，NRX

在所有 SNR 條件下均優於傳統解碼器；另一張圖則比較不同訓練迭代次數及場域微調對 NRX 的影響，結果表明微調與增加迭代皆能顯著提升性能。



(圖九)：NRX 與傳統解碼性能比較。(圖十)：不同迭代次數的 NRX 性能比較。

## 4 結論與展望：

從結論上來說，神經接收器確實對於在基礎通道有位元錯誤率減少的優勢，其最大的特點莫過於可針對特定場域進行神經網路架構權重的更新，這也解決上述內容與參考文獻所提到的硬體資源浪費，而只要透過少量的訓練資料集，就可以得出很好的性能，這為此專題其最大的優勢。

至於未來發展層面，因為系統架構會變得更加複雜，因此在於訓練模型上可能會有一些過擬合或是性能不佳的問題，我認為可以換另外一種神經網路架構(RNN、Transformer ) 以此來得出更優秀性能的神經接收器。

## 參考文獻

- [1] M. B. Fischer, S. Dörner, S. Cammerer, T. Shimizu, H. Lu, and S. ten Brink, "Adaptive neural network-based OFDM receivers" in 2022 IEEE 23rd International Workshop on Signal Processing Advances in Wireless Communication (SPAWC). IEEE, 2022, pp. 1–5.
- [2] J. Hoydis, F. A. Aoudia, S. Cammerer, M. Nimier-David, N. Binder, G. Marcus, and A. Keller, "Sionna RT: Differentiable ray tracing for radio propagation modeling," in 2023 IEEE Globecom Workshops. IEEE, Mar. 2023, pp. 317–321.
- [3] 位移洗牌式渦輪解碼器\_\_臺灣博碩士論文知識加值系統
- [4] 適用於第四代行動通訊之平行渦輪碼解碼器硬體架構
- [5] S. Cammerer, F. Aït Aoudia, J. Hoydis, A. Oeldemann, A. Roessler, T. Mayer and A. Keller, "[A Neural Receiver for 5G NR Multi-user MIMO](<https://arxiv.org/pdf/2312.02601>)", IEEE Workshops (GC Wkshps), Dec. 2023.
- [6] 在 5G 網路下針對低密度奇偶校驗碼與極化碼之通用信度傳播解碼器設計與晶片實現
- [7] [https://jhoydis.github.io/sionna-0.19.2-doc/examples/Neural\\_Receiver.html](https://jhoydis.github.io/sionna-0.19.2-doc/examples/Neural_Receiver.html)

注意事項：

- 整份文件(含封面)至多 10 頁，超出部分不予審查。
- 內文字型大小不得低於 12 pt，文字行距以單行間距為主。
- 請另存為 PDF 後上傳。
- 黑色底線之部分為建議之報告章節編排，其中摘要、專題簡介、結論與展望、以及參考文獻四個項目為必填，其他的章節可以自行刪除新增。
- 所有標注藍色字部分之說明請於繳交前刪除。